

VoltWise — Technická dokumentace

Česká AI Olympiáda 2026 · AI Startup · krajské kolo Praha · zadání AIO_PHA-02-PHA Tým notokens · „Praha v pohybu a pod proudem“

VoltWise je B2G datová služba, která pomocí AI vyhodnotí pro **každou zónu Prahy**, kde má smysl stavět dobíjecí stanice — tak, aby město neutopilo peníze v prázdných dobíječkách a aby nová zátěž nepřetížila lokální síť. Propojuje **mobilitu** (kde a kolik se bude nabíjet) s **energetikou** (kde síť unese zátěž), což je podle zadání nejsilnější možná cesta.

1 · Problém a zákazník

Klimatický plán hl. m. Prahy do 2030 cílí na **až 10 000 veřejných dobíjecích stanic** (Generel HMP střední scénář: ~180 000 EV a min. 4 500 stanic). Investice jde do miliard. Z oborových dat ale **~30 % veřejných dobíječek končí podvyužitých** — postavených bez datové analýzy poptávky a kapacity sítě. To je mrtvý kapitál a zároveň riziko: nová rychlonabíjecí zátěž ve večerní špičce může lokálně přetížit transformační stanici (TS).

Zákazník (instituce)	Hl. m. Praha / městská část / Operátor ICT (Golemio) / distributor (PRE) / energetická komunita
Konkrétní role	plánovač mobility na magistrátu, energetik distributora
Co ho pálí	kam z omezeného rozpočtu umístit stanice, aby se využily a síť je unesla
Dnešní stav ho stojí	desítky milionů Kč v podvyužitých stanicích + riziko lokálního přetížení

VoltWise dává odpověď, kterou tabulka „hodně lidí → velký hub“ nedá: **kde se vyplatí stavět s ohledem na poptávku 2030 × rezervu sítě × mezeru v pokrytí × férovost.**

2 · Data: reálné vs. modelové, a jak jsme je čistili

Jednotkou je **zóna odvozená od transformační stanice (TS)**. Pracujeme s bohatým datasetem Linie A (Nabíjení a síť).

Soubor	Obsah	Řádků	Použití
zones_train.csv	profil zóny: reálné + odvozené vstupy + modelové cíle 2030	2 378	trénink
zones_validation.csv	menší slice (stejně sloupce)	517	holdout — poctivá validace
stations_by_zone_real.csv	reálné stanice MPO přiřazené k zónám	855	obvody, stávající nabídka
grid_capacity_and_reserve_2025.csv	výkon TS, špička, limit, rezerva	3 408	grid headroom
candidate_solutions.csv	katalog 6 typů dobíjecího řešení	6	doporučený typ (porty, kW)
future_scenarios.csv	konzervativní/střední/ambiciózní růst EV	4	pásmo nejistoty 2030
hourly_*	4 reprezentativní týdny po hodinách (zátěž, overload)	2,29 M	časový kontext (lazy)

Kontrola dat (součást úlohy): - **Reálné (_real)** = měřené/registrované (ČSÚ, RÚIAN, IPR, MPO, PRE mapová vrstva). **Odvozené (_derived)** = indexy z reálných vstupů. **Syntetické (_synthetic)** = modelové, **nikoli měření PRE**. Toto rozlišení řídí anti-leakage (§4). - Velká CSV čteme přes **polars (lazy)**, **float32**, nikdy celá do paměti — **hourly_*** má 2,29 M řádků. - Ošetřeny chybějící hodnoty (**ignore_errors**, **infer_schema_length=10000**), různý zápis obcí („Praha 4 – Chodov“ → Praha 4), duplicitní záznamy stanic agregovány na zónu. - **Poctivý limit dat**: většina dnešních veřejných bodů je pomalá (≤ 22 kW), veřejné dobíjení je doplňkové → pracujeme s **pásmem scénářů**, ne s jedním zaručeným číslem (§7).

2.1 Datová pipeline — automatický sběr dat z internetu (jak služba žije zítra)

VoltWise není statická studie nad jedním CSV. Profil každé zóny se **automaticky obnovuje z otevřených datových zdrojů na internetu** — naplánovaná ingestní (research) pipeline data stahuje, čistí, normalizuje na zónu a přepočítá skóre:

Zdroj (online)	Co přináší	Frekvence
Golemio API (golemio.cz/data)	parkování, P+R obsazenost, dojezdové doby (Waze), polohy PID	denně / real-time
opendata.praha.eu	obecná otevřená městská data (zástavba, vybavenost)	měsíčně
Smart Prague / PRE pilot	obsazenost stanic, odběr kWh, doba nabíjení	denně
MPO registr dobíjecích stanic	nově zprovozněné veřejné stanice	týdně
ČSÚ / RÚIAN	obyvatelstvo, byty, nová výstavba	čtvrtletně

Pipeline (**requests / polars** ETL → feature store → přetrénování modelu) běží jako naplánovaná úloha; čerstvá data tak průběžně **zpřesňují predikci poptávky i rezervu sítě**. Tím služba splňuje požadavek „sběr a údržba dat v čase“ — neexistuje okamžik, kdy by data zastarala bez povšimnutí.

3 · AI jádro — dva běžící modely + skóre

VoltWise **není jednorázová analýza zakončená grafem**. Jsou to dva natrénované modely, které v produktu trvale pracují a přepočítají se, jak přicházejí nová data.

3.1 Predikce poptávky (regrese) — hlavní AI signál

- **Model:** LightGBM regrese (`n_estimators=600` , `lr=0.03` , `num_leaves=31`), CPU.
- **Cíl:** `estimated_ev_count_2030_synthetic` — predikovaná poptávka po nabíjení v zóně 2030.
- **Featury:** 60 reálných/odvozených/2025-kapacitních sloupců (zástavba, byty bez stání, landuse, parking, veřejné osvětlení, MHD, silnice, **rezerva sítě 2025**, indexy rezidenčnosti a citlivosti sítě). Bohatý profil, ne jeden údaj.

3.2 Doporučení typu stanice (klasifikace) — recommender

- **Model:** LightGBM klasifikátor → jeden ze **6 typů** z `candidate_solutions.csv` (`residential_ac_small/medium` , `destination_dc50` , `fast_hub_150` , `mixed_mobility_hub` , `none_monitor`). Z typu se doplní počet portů a výkon kW.

3.3 Suitability skóre 0–100 — kompozit, který propojuje mobilitu a energetiku

```
suitability = 100 × ( 0.40 · poptávka_2030      (LightGBM)
                    + 0.30 · coverage_gap      (poptávka – stávající stanice)
                    + 0.15 · grid_headroom      (rezerva TS 2025)
                    + 0.15 · equity_weight )     (domácnosti bez vlastního stání)
```

Každá složka je z reálných dat nebo z modelu, normalizovaná přes celé město. Skóre je **plně interpretovatelné** — appka u každé zóny ukáže `top_reasons` („vysoká poptávka; málo stávajících stanic; volná síť; mnoho bytů bez stání“).

3.4 Výstupní kontrakt

Modely vyrobí jediný soubor `submissions/app_zone_scores.csv` (16 sloupců), který appka čte: `grid_zone_id`, `district`, `center_lat/lon`, `population`, `predicted_demand_2030`, `grid_headroom`, `current_stations`, `coverage_gap`, `equity_weight`, `suitability_score`, `recommended_type`, `recommended_ports`, `recommended_total_kw`, `top_reasons`.

Skórujeme všech 2 895 zón = celá Praha, 22 správních obvodů (sandbox umožňuje skórovat vše; metriky měříme jen na odděleném holdoutu — §4).

4 · Proč je to opravdová AI (ne tabulka) + anti-leakage

Že to není triviální pravidlo

Porovnáváme proti **populační baseline** („víc lidí → víc nabíjení“, což zvládne tabulka):

Model	MAE (EV/den)	RMSE	Precision@50
LightGBM (náš)	4,63	7,67	0,84
baseline ~ populace	5,66	7,98	0,84
baseline = průměr	29,47	38,34	0,08

→ Model má **MAE o 18,1 % nižší** než triviální populační pravidlo a najde i **méně očekávané, ale sedící** zóny (malá populace, ale tranzit + volná síť + žádné stanice), které pravidlo mine. **Recommender typu stanice: 83,8 % přesnost** na holdoutu.

Anti-leakage (kontrolováno kódem)

Sdílená funkce `feature_cols` automaticky **vyřazuje z featur** vše, co je cíl nebo z cíle odvozené: `target_*` , `_2030_synthetic` (tedy i `estimated_ev_count_2030`), `recommended_*` , `risk_overload` , ID sloupce a textové sloupce. V kódu je **runtime `assert not leaky`** . Modely se učí z 60 reálných/2025 featur, **nikdy z budoucích cílů**.

Poctivá validace

Trénujeme na `zones_train`, **metriky měříme jen na odděleném `zones_validation`** (holdout). Predikce na trénovacích zónách (pro mapu celého města) jsou označené jako in-sample; **čísla v dokumentaci a v appce pocházejí výhradně z holdoutu**. Žádné odevzdání na skryté labelsy — data jsou sandbox.

5 · Běžící produkt (živá ukázka)

Streamlit dashboard `src/app_premium.py` nad výstupem modelu — **navržený pro městského úředníka**:

- **3 přepínatelné heatmapy** celé Prahy (model-driven): ① vhodnost (suitability), ② projektovaná spotřeba 2030, ③ potřeba nových stanic 2030; hlavní vrstva = souvislý heat **zelená** → **červená**.
- **Filtr po obvodech** (Praha 1–22), min. skóre, slider „kolik nových stanic plánuješ“ → **očíslované špendlíky = KAM stavět**.
- Vrstva „**všechny potřebné stanice 2030**“ obarvená dle typu stanice (AC/DC/hub).
- **Detailní popup „proč“** u každé zóny, **žebříček TOP-N**, **export CSV/GeoJSON**.
- **Rozpočtový optimalizátor** („mám X mil. Kč → kam pro max pokrytí poptávky“).
- Tab **Model & metodika**: živé metriky, anti-leakage, etika.

Stack: **Python · LightGBM · scikit-learn · polars · Streamlit · folium**. Trénink ~2 min na CPU (Intel Lunar Lake, bez CUDA).

6 · Byznys: kontinuální služba, ne studie

Otázka	VoltWise
Zákazník	Magistrát HMP / MČ / Operátor ICT / PRE / energetická komunita
Opakovaná hodnota	skóre se přepočítává , jak přibývají EV, stanice a mění se rezerva sítě — ne jednorázový výpočet
Sběr dat v čase	napojení na pilot PRE/Smart Prague (obsazenost, kWh, doba nabíjení) a Golemio (parkování, doprava); registr EV; aktualizace profilu zóny
Monetizace	roční licence (SaaS) ~300 tis. Kč/rok pro město/MČ; vyšší tarif pro distributora
Návratnost	cílení místo plošného rozmístění sníží podíl podvyužitých stanic z ~30 % na ~10 % → z rozpočtu např. 60 mil. Kč uchrání ~12 mil. Kč ; licence se vrátí už při jediné nepostavené prázdné stanici
Škálování	další města (Brno, Plzeň, Ostrava) stejným pipeline; další infrastruktura (P+R, sdílená mobilita, energetické komunity)

Čísla jsou **konzervativní a obhajitelná** — žádné spekulativní násobky. Náklady stanic vychází z reálu ČR (veřejná AC ~0,2–0,4 mil. Kč, DC rychlo ~1–2 mil. Kč).

7 · AI etika — všechny 4 oblasti

1. **Chybná predikce a odpovědnost**. Výstup je **podpora rozhodnutí, ne automat** — člověk (úředník) rozhoduje. Kvalitu měříme na holdoutu a model lze **přetrénovat**, jak dorazí reálná data o obsazenosti z pilotu PRE → chyba se pozná (skutečné využití vs. predikce) a opraví.
2. **Soukromí**. Pracujeme **výhradně se zónovými agregáty** (TS-oblast, ČSÚ/RÚIAN), **žádná data o jednotlivcích**, žádné individuální trasy či platby. Profil zóny nelze rozklíčovat na osobu.
3. **Spravedlnost / cold-start**. Spirálu „málo dat v okrajové čtvrti → horší doporučení → žádná infrastruktura → lidé nepřejdou → dál chybí data“ **aktivně lámeme**: složka `equity_weight` (index domácností bez vlastního

stání) **zvyšuje skóre okrajových a méně bohatých čtvrtí**. Content-based featury (profil zóny), ne collaborative, takže **řídke zóny nejsou znevýhodněné**.

4. **Komunikace nejistoty**. Predikce 2030 **prezentujeme jako pásmo scénářů** (`future_scenarios.csv` : konzervativní / střední / ambiciózní), ne jako jedno „zaručené“ číslo. U řídkých zón hlásíme nižší jistotu. Město tak nedělá přehnaně sebejistá rozhodnutí.

8 · Náš úhel + zahraniční inspirace na Prahu

Nejzřejmější řešení je „kam dát velký hub“. My místo toho skórujeme **každou zónu** kompozitem, který **propojuje mobilitu a energetiku** — poptávka × rezerva sítě × mezera × férovost. To je ten průnik, který zadání označuje za nejsilnější.

Zahraniční trend lokalizovaný na Prahu: ve světě vznikají *EV charging suitability / grid-aware siting* nástroje (např. NCSU EVSE suitability map s vrstvou **grid headroom**, StreetLight a Justice40 **equity** vrstvy, EV-Planner multikriteriální optimalizace). Přenášíme jejich tři diferenciátory — **AI suitability scoring, vrstva kapacity sítě, equity analýza** — na pražská data a cíle (Klimatický plán 2030, Smart Prague/PRE pilot, Generel HMP). V Praze to sedí o to víc, že **rezerva TS je úzké hrdlo** a podíl bytů bez vlastního stání je vysoký.

9 · Shrnutí pro porotu

Kritérium (váha)	Jak ho plníme
Technické (40)	2 běžící modely (regrese + recommender), MAE –18,1 % vs baseline, P@50 0,84, recommender 83,8 %, kontrolovaný anti-leakage, interpretace „proč“, cold-start v modelu
Byznys (40)	jasný zákazník (HMP/PRE), roční licence, sběr dat v čase (PRE/Golemio), obhajitelná návratnost, škálování na další města
Prezentace + etika + region (20)	běžící živé demo, všechny 4 etické oblasti , napojení na Klimatický plán/Smart Prague/IPR, vlastní úhel + zahraniční inspirace, pásmo nejistoty

Reprodukce: `python src/generate_scores.py → streamlit run src/app_premium.py`.

AIO_PHA-02-PHA · Česká AI Olympiáda 2026 · tým notokens · data = sandbox (reálná + modelová)